

# Tài liệu chi tiết cho dự án RAE XLA và JAX

Nhánh TorchXLA/TPU và lớp tương thích JAX/NNX của dự án Representation Autoencoders

Ngày 6 tháng 4 năm 2026

## Mục lục

|          |                                                       |          |
|----------|-------------------------------------------------------|----------|
| <b>1</b> | <b>Tổng quan dự án</b>                                | <b>3</b> |
| 1.1      | Mục tiêu . . . . .                                    | 3        |
| 1.2      | Hai giai đoạn chính . . . . .                         | 3        |
| 1.2.1    | Stage 1 . . . . .                                     | 3        |
| 1.2.2    | Stage 2 . . . . .                                     | 3        |
| 1.3      | Phạm vi của branch hiện tại . . . . .                 | 3        |
| 1.4      | Giới hạn hiện tại . . . . .                           | 3        |
| 1.5      | Dòng dữ liệu cấp cao . . . . .                        | 4        |
| 1.6      | Ý tưởng của đường JAX . . . . .                       | 4        |
| 1.7      | Tài liệu trong repo . . . . .                         | 4        |
| <b>2</b> | <b>Kiến trúc hệ thống</b>                             | <b>4</b> |
| 2.1      | Bản đồ codebase . . . . .                             | 4        |
| 2.2      | Stage 1: Representation Autoencoder . . . . .         | 5        |
| 2.3      | Stage 2: SiT trong không gian latent . . . . .        | 5        |
| 2.4      | Transport objective . . . . .                         | 6        |
| 2.5      | Lớp adapter JAX . . . . .                             | 6        |
| 2.6      | Hai mô hình thực thi . . . . .                        | 7        |
| 2.6.1    | TorchXLA . . . . .                                    | 7        |
| 2.6.2    | JAX / NNX . . . . .                                   | 7        |
| 2.7      | Checkpoint và tương thích trọng số . . . . .          | 7        |
| <b>3</b> | <b>Workflow thực chiến</b>                            | <b>7</b> |
| 3.1      | Cài đặt môi trường . . . . .                          | 7        |
| 3.1.1    | Đường XLA . . . . .                                   | 7        |
| 3.1.2    | Phần bổ sung cho JAX / NNX . . . . .                  | 8        |
| 3.2      | Chuẩn bị model và dữ liệu . . . . .                   | 8        |
| 3.2.1    | Model . . . . .                                       | 8        |
| 3.2.2    | Dữ liệu . . . . .                                     | 8        |
| 3.3      | Kiểm tra Stage 1 bằng reconstruction . . . . .        | 8        |
| 3.3.1    | Đường XLA / PyTorch . . . . .                         | 8        |
| 3.3.2    | Đường JAX . . . . .                                   | 9        |
| 3.3.3    | Tính latent stat cho Stage 1 trên đường JAX . . . . . | 9        |
| 3.3.4    | Reconstruction cả thư mục trên đường JAX . . . . .    | 9        |
| 3.4      | Huấn luyện Stage 2 trên TPU bằng TorchXLA . . . . .   | 9        |

|          |                                                |           |
|----------|------------------------------------------------|-----------|
| 3.5      | Huấn luyện Stage 2 bằng JAX / NNX . . . . .    | 10        |
| 3.6      | Wandb logging . . . . .                        | 10        |
| 3.7      | FID trong train loop . . . . .                 | 11        |
| 3.8      | Sampling Stage 2 . . . . .                     | 11        |
| 3.8.1    | JAX một lệnh . . . . .                         | 11        |
| 3.8.2    | JAX distributed . . . . .                      | 11        |
| 3.9      | Đẩy artifact lên Hugging Face . . . . .        | 12        |
| 3.9.1    | Lệnh độc lập . . . . .                         | 12        |
| 3.9.2    | Tích hợp ngay trong train . . . . .            | 12        |
| 3.10     | Notebook Kaggle TPU cho CelebA . . . . .       | 12        |
| <b>4</b> | <b>Cấu hình và ánh xạ sang JAX</b>             | <b>13</b> |
| 4.1      | Các block config chính . . . . .               | 13        |
| 4.2      | Ma trận script và block config . . . . .       | 14        |
| 4.3      | Block stage_1 . . . . .                        | 14        |
| 4.4      | Block stage_2 . . . . .                        | 14        |
| 4.5      | Block guidance . . . . .                       | 15        |
| 4.6      | Block training . . . . .                       | 15        |
| 4.7      | Block source . . . . .                         | 16        |
| 4.8      | Block eval . . . . .                           | 17        |
| 4.9      | Override từ CLI . . . . .                      | 17        |
| <b>5</b> | <b>Vận hành, artifact và FID</b>               | <b>17</b> |
| 5.1      | Sampling Stage 2 trên đường JAX . . . . .      | 17        |
| 5.1.1    | Sampling nhanh . . . . .                       | 17        |
| 5.1.2    | Sampling phân tán . . . . .                    | 17        |
| 5.2      | Build reference statistics cho FID . . . . .   | 18        |
| 5.3      | Artifact của Stage 2 training . . . . .        | 18        |
| 5.3.1    | Đường XLA . . . . .                            | 18        |
| 5.3.2    | Đường JAX . . . . .                            | 18        |
| 5.4      | Đẩy model lên Hugging Face . . . . .           | 19        |
| 5.5      | Các lưu ý vận hành quan trọng . . . . .        | 19        |
| 5.6      | Checklist thực tế trước khi chạy dài . . . . . | 20        |

## 1. Tổng quan dự án

### 1.1. Mục tiêu

Dự án này triển khai pipeline tạo ảnh hai giai đoạn dựa trên *Representation Autoencoders* (RAE). Ở thời điểm hiện tại, repo có hai đường chạy chính:

- `src/`: nhánh TorchXLA, tối ưu cho TPU với train và sampling Stage 2, reconstruction Stage 1, và FID phía host;
- `src_jax/`: lớp tương thích JAX/NNX, giữ nguyên schema YAML của repo nhưng ánh xạ sang backend NNX để tránh nhân đôi toàn bộ codebase.

### 1.2. Hai giai đoạn chính

#### 1.2.1. Stage 1

Stage 1 dùng một encoder biểu diễn đã được pretrain và đóng băng, kết hợp với một decoder ViT để tái tạo ảnh. Đầu ra của Stage 1 là latent giàu ngữ nghĩa hơn latent VAE thông thường.

#### 1.2.2. Stage 2

Stage 2 học mô hình diffusion transformer trong không gian latent của Stage 1. Thay vì học trực tiếp trên pixel, mô hình học quy luật biến đổi của latent, sau đó giải mã latent sinh được thành ảnh RGB qua decoder của RAE.

### 1.3. Phạm vi của branch hiện tại

Nhánh hiện tại không chỉ có đường TorchXLA mà còn có adapter JAX mỏng. Phần được hỗ trợ thực dụng nhất là:

- huấn luyện Stage 2 bằng `src/train.py` trên TPU;
- huấn luyện Stage 2 bằng `src_jax/train.py` trên JAX/NNX;
- sampling Stage 2 bằng cả `src/` và `src_jax/`;
- reconstruction Stage 1 để kiểm tra encoder-decoder trên cả hai đường;
- logging qua wandb;
- upload artifact hoặc workdir lên Hugging Face;
- FID offline, và online FID trong train loop ở đường XLA.

### 1.4. Giới hạn hiện tại

- `src/` vẫn không có endpoint riêng cho huấn luyện Stage 1 trên XLA;
- `src_jax/` cố ý chưa port toàn bộ vòng huấn luyện Stage 1 kiểu GAN + LPIPS + discriminator, vì phần đó sẽ làm codebase lớn và khó bảo trì hơn đáng kể.

## 1.5. Dòng dữ liệu cấp cao

| Bước | Mô tả                                                                      |
|------|----------------------------------------------------------------------------|
| 1    | Ảnh đầu vào được đưa qua encoder của Stage 1                               |
| 2    | Encoder sinh latent tensor có kích thước như <code>misc.latent_size</code> |
| 3    | Stage 2 học transport objective trên latent đó                             |
| 4    | Khi sampling, latent được sinh bởi Stage 2                                 |
| 5    | Decoder của Stage 1 giải mã latent thành ảnh RGB                           |

## 1.6. Ý tưởng của đường JAX

Đường JAX không tạo thêm một schema config mới. Thay vào đó:

- vẫn đọc các block `stage_1`, `stage_2`, `transport`, `sampler`, `guidance`, `misc`, `training`, `eval`;
- dùng `src_jax/config_adapter.py` để chuyển YAML hiện có sang config mà backend NNX hiểu được;
- bootstrap backend `diffuse_nnx` theo commit cố định để branch gọn hơn, không phải chép toàn bộ framework vào repo.

## 1.7. Tài liệu trong repo

Ngoài PDF này, repo còn có bộ tài liệu markdown trong `docs/`. Phần markdown thiên về runbook ngắn và tra cứu nhanh; PDF này gom lại kiến trúc, workflow, cấu hình và vận hành cho cả đường XLA lẫn JAX.

## 2. Kiến trúc hệ thống

### 2.1. Bản đồ codebase

```

configs/
  stage1/
  stage2/
src/
  stage1/
  stage2/
  utils/
  train.py
  sample.py
  sample_ddp.py
  stage1_sample.py
  stage1_sample_ddp.py
  build_fid_stats.py
  evaluate_fid.py
src_jax/
  backend_overlay/
  vendor.py
  moe1/
  config_adapter.py
  stage2_runtime.py
  stage1_runtime.py
  build_stage1_stats.py

```

```

build_source_gmm.py
export_celebahq_hf.py
export_celebahq_tfds.py
reconstruct_folder.py
hf_utils.py
train.py
sample.py
sample_ddp.py
stage1_sample.py
push_hf.py
raes-jax-celeba-kaggle-tpuv5e8-sitdh-b-moe1.ipynb
raes-jax-celeba-kaggle-tpuv5e8-sitdh-b-moe1-resume.ipynb

```

## 2.2. Stage 1: Representation Autoencoder

Thành phần gốc của Stage 1 nằm trong `src/stage1/rae.py`. Lớp RAE kết hợp:

- encoder ở `src/stage1/encoders/`,
- decoder ở `src/stage1/decoders/`,
- latent normalization qua `normalization_stat_path`,
- latent noising qua `noise_tau`.

Hành vi chính:

- `encode(x)` resize đầu vào về đúng độ phân giải của encoder, chuẩn hóa theo image processor, chạy encoder, reshape latent về dạng 2D nếu cần, rồi áp normalization;
- `decode(z)` đảo normalization, đổi latent về dạng sequence nếu cần, rồi giải mã thành ảnh RGB bằng decoder ViT.

Ở đường JAX, `src_jax/stage1_runtime.py` không tự viết lại toàn bộ RAE trong repo này. Nó gọi backend NNX, nhưng vẫn dùng đúng các giá trị cấu hình trong block `stage_1`.

## 2.3. Stage 2: SiT trong không gian latent

Surface Stage 2 mặc định của branch này nằm ở `src/stage2/models/SiT.py`. Lớp SiTDH là alias reop-facing cho backbone DH/two-tower DiTwDDTHead trong `src/stage2/models/DDT.py`. Điều này giữ cho kiến trúc Stage 2 khớp với biến thể DH, còn objective trên đường JAX vẫn đi qua interface `sit`.

Các đặc điểm quan trọng:

- đầu vào là latent thay vì pixel;
- embedding thời gian bằng Gaussian Fourier features;
- class conditioning bằng `LabelEmbedder`;
- tùy chọn ROPE, RMSNorm, SwiGLU, qk-norm;
- hỗ trợ classifier-free guidance và autoguidance khi sampling.

Đường JAX ánh xạ `stage_2.target` sang backbone tương ứng của backend NNX:

- SiTDH  $\rightarrow$  `lightning_ddt`,

- LightningDiT  $\rightarrow$  lightning\_dit,
- các target DDT legacy  $\rightarrow$  lightning\_ddt,
- các target kiểu DiT khác  $\rightarrow$  dit.

## 2.4. Transport objective

Phần này nằm trong `src/stage2/transport/transport.py`. Đây là lớp trung gian giữa latent diffusion model và train loop.

Nhiệm vụ của transport:

- lấy mẫu thời gian  $t$ ;
- xây dựng đường nối giữa noise và dữ liệu thật;
- tính target phù hợp với loại output của model;
- trả về drift function để phục vụ ODE hoặc SDE sampler.

Ở đường JAX, adapter không giữ lại implementation transport gốc này. Nó ánh xạ các ý nghĩa tương đương sang interface của backend NNX, chủ yếu là SiT với sampling kiểu Euler.

## 2.5. Lớp adapter JAX

| File                                         | Vai trò                                                                                                                                            |
|----------------------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------|
| <code>src_jax/vendor.py</code>               | Bootstrap diffuse_nnx vào <code>■/.cache/rae_jax/diffuse_nnx</code> và pin commit                                                                  |
| <code>src_jax/config_adapter.py</code>       | Chuyển YAML OmegaConf của repo sang config backend NNX, forward random_flip/prefetch_factor và mặc định bật flip cho config train CelebA-HQ        |
| <code>src_jax/stage2_runtime.py</code>       | Train, sampling, load checkpoint PyTorch hoặc Orbax, JAX validation-loss integration, raw-image random flip tùy chọn, FID glue, wandb bridge       |
| <code>src_jax/stage1_runtime.py</code>       | Load encoder Stage 1 JAX, reconstruction một ảnh, reconstruction cả thư mục và tích lũy latent stat                                                |
| <code>src_jax/build_stage1_stats.py</code>   | Export file stat.pt theo định dạng mean / var để dùng lại cho Stage 1                                                                              |
| <code>src_jax/export_celebahq_hf.py</code>   | Download eurecom-ds/celeba-hq-256 từ Hugging Face rồi export thành cây ImageFolder cho pipeline JAX hiện tại                                       |
| <code>src_jax/export_celebahq_tfds.py</code> | Export TFDS celeb_a_hq/256 thành cây ImageFolder cho pipeline JAX hiện tại và ép protobuf runtime kiểu Python để tránh lỗi import TFDS trên Kaggle |
| <code>src_jax/build_fid_stats.py</code>      | Build fid_ref bằng đúng detector Flax Inception của backend JAX                                                                                    |
| <code>src_jax/reconstruct_folder.py</code>   | Export reconstruction cho cả thư mục ảnh theo pipeline JAX                                                                                         |
| <code>src_jax/hf_utils.py</code>             | Upload file hoặc thư mục lên Hugging Face                                                                                                          |

## 2.6. Hai mô hình thực thi

### 2.6.1. TorchXLA

Các entrypoint distributed trong `src/` dùng `xmp.spawn(...)` và mỗi TPU core chạy một process riêng. Các primitive quan trọng:

- `DistributedSampler`,
- `ParallelLoader`,
- `xm.optimizer_step(...)`,
- `xm.rendezvous(...)` và `xm.mesh_reduce(...)`.

### 2.6.2. JAX / NNX

Đường `src_jax/` không tự quản lý toàn bộ graph, checkpoint và sampler ở mức thấp. Nó dựa vào backend NNX để:

- tạo model, optimizer, sampler và EMA,
- quản lý checkpoint Orbx,
- chạy sampling và FID trong định dạng tensor NHWC của JAX,
- mở rộng sang nhiều process JAX nếu môi trường đã cấu hình phù hợp.

Repo cũng vá backend này để EMA khởi tạo từ bản copy của model hiện thời thay vì một cây tham số toàn số 0. Nhờ vậy `ema_network_samples` và online FID không còn bắt đầu từ một EMA cold-start sai ngay từ step đầu.

## 2.7. Checkpoint và tương thích trọng số

Với branch `jax-sit-dh-moe1`, checkpoint Stage 2 phải khớp shape của SiTDH/LightningDiT:

- nếu `stage_2.ckpt` là file PyTorch `.pt`, adapter sẽ port state dict sang NNX để inference hoặc khởi tạo train nếu checkpoint đó đã tương thích với SiTDH;
- nếu `stage_2.ckpt` là thư mục checkpoint Orbx, adapter sẽ restore trực tiếp run JAX SiTDH trước đó;
- checkpoint DDT legacy không được tự động convert trên branch này;
- decoder Stage 1 ở đường JAX vẫn dùng được checkpoint decoder PyTorch.

## 3. Workflow thực chiến

### 3.1. Cài đặt môi trường

Repo hiện có hai cụm phụ thuộc chính.

#### 3.1.1. Đường XLA

```
conda create -n rae python=3.10 -y
conda activate rae
pip install uv
```

```
uv pip install torch~=2.5.0 torch_xla[tpu]~=2.5.0 torchvision==0.20.1 -f https://
    storage.googleapis.com/libtpu-releases/index.html
uv pip install timm==0.9.16 accelerate==0.23.0 torchdiffeq==0.2.5 wandb scipy torch-
    fidelity
uv pip install "numpy<2" "transformers==4.57.1" einops
```

### 3.1.2. Phần bổ sung cho JAX / NNX

```
uv pip install "jax[cuda12]~=0.5.1" flax==0.10.4 optax==0.2.4 orbax-checkpoint==0.11.16
uv pip install ml-collections clu absl-py etils huggingface_hub
```

Lần chạy JAX đầu tiên sẽ tự bootstrap backend `diffuse_nnx` vào thư mục `./.cache/rae_jax/diffuse_nnx`. Các notebook JAX trên Kaggle không còn lặp lại từng lệnh `uv pip install` này; chúng đặt `UV_PROJECT_ENVIRONMENT`: `UV_CACHE_DIR=/tmp/uv-cache`, rồi chạy `uv sync -q` theo `pyproject.toml` của repo trước các cell phụ thuộc package. Repo này tự vá backend `diffuse_nnx` để import các model Dinov2 từ subpackage của `transformers`, nên nên dùng `transformers==4.57.1` cho đường này. Patch này cũng chuyển `google-cloud-storage` sang import lười, nên đường Stage 1 với RAE/DINO không cần cài package đó trừ khi bạn thực sự dùng các thành phần backend có tải asset từ GCS. Patch bootstrap này cũng sửa khởi tạo EMA của backend để EMA bắt đầu từ bản copy của model hiện thời thay vì cây tham số toàn số 0. Nếu bạn resume một checkpoint Orbax cũ được tạo trước khi có fix này, checkpoint đó vẫn mang EMA đã lưu sẵn trước đó. Adapter cũng tự suy ra `downsample_factor` và `latent_channels` từ `misc.latent_size`, nên bước preview sample và FID của backend vẫn chạy ở latent resolution thay vì lỗi cấp phát noise theo image resolution.

## 3.2. Chuẩn bị model và dữ liệu

### 3.2.1. Model

```
hf download nyu-visionx/RAE-collections --local-dir models
```

### 3.2.2. Dữ liệu

Hầu hết các script dùng dữ liệu dạng `ImageFolder`. Ví dụ:

```
dataset_root/
  class_a/
    0001.png
  class_b/
    0002.png
```

## 3.3. Kiểm tra Stage 1 bằng reconstruction

### 3.3.1. Đường XLA / PyTorch

```
python src/stage1_sample.py \
  --config <config> \
  --image assets/pixabay_cat.png \
  --output recon.png
```



### 3.3.2. Đường JAX

```
python3 src_jax/stage1_sample.py \
  --config <config> \
  --image assets/pixabay_cat.png \
  --output recon_jax.png
```

Lệnh này phù hợp để xác nhận:

- checkpoint decoder Stage 1 có load được hay không,
- latent shape có đúng hay không,
- preprocessing của encoder có khớp hay không.

### 3.3.3. Tính latent stat cho Stage 1 trên đường JAX

Với dataset mới như CelebA, nên tạo một file bootstrap identity stat trước (mean = 0, var = 1), rồi chạy:

```
python3 src_jax/build_stage1_stats.py \
  --config <stage1_config> \
  --input <train_imagefolder> \
  --output <stage1_stat.pt> \
  --batch-size 16 \
  --set stage_1.params.normalization_stat_path=<bootstrap_identity_stat.pt>
```

File stage1\_stat.pt tạo ra vẫn cùng định dạng với repo gốc, nên dùng lại được cho cả đường src/ lẫn src\_jax/. Các lệnh Stage 1 thuần ở JAX có thể chạy với YAML chỉ khai báo stage\_1; chúng không bắt buộc có stage\_2.target.

### 3.3.4. Reconstruction cả thư mục trên đường JAX

```
python3 src_jax/reconstruct_folder.py \
  --config <stage1_config> \
  --input <val_imagefolder> \
  --output-dir recon_jax_dir \
  --batch-size 8
```

Lệnh này hữu ích khi muốn export reconstruction set trước khi build FID reference hoặc khi cần so sánh decoder Stage 1 giữa các checkpoint.

## 3.4. Huấn luyện Stage 2 trên TPU bằng TorchXLA

```
python src/train.py \
  --config configs/stage2/training/ImageNet256/SiTDLH-XL_DINOv2-B.yaml \
  --data-path <imagenet_train_split> \
  --results-dir results \
  --image-size 256 \
  --precision bf16
```

Trong mỗi optimizer step, train loop thực hiện:

1. center crop và đưa ảnh thành tensor;

2. mã hóa ảnh bằng RAE;
3. tính transport loss trong latent space;
4. step optimizer và scheduler trên TPU;
5. update EMA;
6. chạy logging, checkpointing, preview sample, validation và FID theo cadence.

### 3.5. Huấn luyện Stage 2 bằng JAX / NNX

```
python3 src_jax/train.py \
  --config configs/stage2/training/ImageNet256/SiTdh-XL_DINOv2-B.yaml \
  --data-path <imagenet_train_root> \
  --results-dir results_jax \
  --precision bf16 \
  --wandb
```

Trên Kaggle TPU, bộ notebook JAX của branch này hiện đã chuẩn hoá về `-set training.num_workers=16`, `-set training.prefetch_factor=4`, và `-set eval.prefetch_factor=4`. Mốc này giữ backend PyTorch loader ở vùng ổn định cho notebook JAX đóng gói sẵn, đồng thời vẫn cho host queue trước vài batch để chồng lấp I/O với TPU. Adapter cũng tự tắt backend TensorBoard summary writer trên Kaggle và giữ metric ở stdout cùng wandb.

Điểm quan trọng:

- vẫn dùng cùng file YAML của repo;
- hỗ trợ `-set key=value` để override nhanh từ CLI;
- hỗ trợ `-wandb-run-id <existing_run_id>` để bind một legacy workdir với đúng W&B run cũ đúng một lần;
- nếu `stage_2.ckpt` là file PyTorch `.pt`, adapter sẽ port trọng số sang NNX để khởi tạo;
- nếu `stage_2.ckpt` là thư mục Orbax, adapter sẽ restore run JAX trước đó.

Nếu bật `training.log_rae_latent_stats=true`, train loop JAX sẽ log `train_rae_latent_rms` và `train_rae_latent_var`. Nếu bật `training.log_activation_stats=true`, backend sẽ trả thêm intermediate feature của SiTDH để log RMS/variance cho output và từng block encoder/decoder, ví dụ `train_sitdh_output_rms`, `train_sitdh_act_enc_00_rms`, và `train_sitdh_act_dec_01_var`. Bù lại, các metric activation này có chi phí throughput và bộ nhớ rõ rệt hơn train loop mặc định. Nếu cần giảm độ trễ host-side, có thể override thêm `training.prefetch_factor` và `eval.prefetch_factor`; các key này được adapter forward thẳng sang DataLoader của đường JAX.

### 3.6. Wandb logging

Biến môi trường khuyến nghị:

```
export ENTITY=<wandb_entity>
export PROJECT=<wandb_project>
export WANDB_KEY=<wandb_api_key>
```

Đường JAX cũng chấp nhận các tên WANDB\_ENTITY và WANDB\_API\_KEY. Adapter sẽ bridge các tên legacy ở trên nếu chúng đã được export sẵn. Với `src_jax/train.py`, mỗi workdir mỗi giờ sẽ ghi `wandb_run.json` để khóa đúng W&B run id của workdir đó. Run mới dùng `resume="never"`; các lần resume sau sẽ đọc lại file này, giữ đúng run id đã bind, rồi tự rewind W&B history về latest checkpoint\_\* step qua `resume_from`. Nhờ đó phần metric đã log sau checkpoint cuối của session cũ sẽ không bị giữ lại sai lịch sử. Nếu resume một Orbax workdir cũ chưa có `wandb_run.json`, cần truyền `-wandb-run-id <existing_run_id>` một lần để bind đúng historical run trước khi train tiếp.

### 3.7. FID trong train loop

Đường XLA hỗ trợ online FID trong `src/train.py`. Ví dụ:

```
eval:
  fid_ref: /path/to/reference_stats.npz
  fid_every: 25000
  fid_num_samples: 4096
  fid_per_proc_batch_size: 4
  fid_batch_size: 128
  fid_device: cpu
  fid_num_threads: 96
```

Đường JAX giờ cũng dùng block `eval` để chạy validation loss trên held-out ImageFolder, log `eval/ema_loss` mặc định và thêm `eval/model_loss` nếu bật `eval_model`. Với online FID, nên xây `fid_ref` bằng detector backend-native qua:

```
python3 src_jax/build_fid_stats.py \
  --input /path/to/reference_images \
  --output /path/to/reference_stats.pkl \
  --batch-size 64 \
  --num-workers 8
```

Trên Kaggle TPU, nên giữ `-num-workers` ở mức vừa phải (0-8 thường là đủ). Đường JAX này dùng worker kiểu spawn khi `num_workers > 0`, nên sạch hơn so với default fork.

Trên đường JAX, metric FID-4K (`cfg=...`) mặc định vẫn chấm EMA. Nếu bật `fid_eval_model`, adapter sẽ log thêm metric riêng FID-4K/model (`cfg=...`) cho online model để bạn đối chiếu trực tiếp với panel `network_samples`.

## 3.8. Sampling Stage 2

### 3.8.1. JAX một lệnh

```
python3 src_jax/sample.py \
  --config configs/stage2/sampling/ImageNet256/SiTDHXL-DINOv2-B_AG.yaml \
  --class-labels 207,360 \
  --output sample_jax.png
```

### 3.8.2. JAX distributed

```
python3 src_jax/sample_ddp.py \
  --config configs/stage2/sampling/ImageNet256/SiTDHXL-DINOv2-B.yaml \
  --sample-dir samples_jax \
```

```
--num-samples 50000 \
--label-sampling equal \
--fid-ref /path/to/reference_stats.npz
```

Các config sampling JAX được commit dưới dạng template. Trước khi chạy sampling, cần tự điền `stage_2.ckpt` và, nếu dùng autoguidance, cả `guidance.guidance_model.ckpt` bằng checkpoint SiTDH tương thích.

### 3.9. Đẩy artifact lên Hugging Face

#### 3.9.1. Lệnh độc lập

```
python3 src_jax/push_hf.py \
--path results_jax/<run_name> \
--repo-id <hf_user_or_org>/<repo_name>
```

#### 3.9.2. Tích hợp ngay trong train

```
python3 src_jax/train.py \
--config <config> \
--data-path <train_root> \
--hf-repo-id <hf_user_or_org>/<repo_name>
```

### 3.10. Notebook Kaggle TPU cho CelebA

Repo hiện ship notebook TPU `raes-jax-celeba-kaggle-tpuv5e8-sitdh-b-moe1.ipynb` để bám đúng flow Kaggle của branch `learned-source`:

- clone repo và checkout branch `jax-sit-dh-moe1`;
- đặt `UV_PROJECT_ENVIRONMENT=/tmp/.venv` và `UV_CACHE_DIR=/tmp/uv-cache`;
- chạy `uv sync -q` từ root của repo;
- chạy các bước phụ thuộc package qua `uv run`;
- chuẩn hoá dataset Kaggle CelebA thành `ImageFolder 256x256`;
- tạo bootstrap identity stat, build latent stat cho Stage 1;
- export reconstruction validation set, build `fid_ref`;
- build artifact diagonal GMM bằng `src_jax/build_source_gmm.py`;
- ghi sẵn config CelebA với `block source.enabled=true` cho `src_jax/train.py`.

Notebook này giữ dataset nguồn mặc định là bộ Kaggle CelebA chuẩn, center-crop và resize về 256x256, rồi materialize dữ liệu thành `/kaggle/working/celeba256_imgfolder`. Các notebook TPU dùng root `ImageFolder` và vẫn giữ `eval.data_path` trên `split val`. Các notebook TPU `moe1` bật `training.log_rae_latent_stats`, `training.log_activation_stats=true`, và export `RAE_JAX_REBUILD_BACKEND=1` để backend overlay luôn recopy interface `sit_gmm_moe1` trong session Kaggle mới. Script `src_jax/build_source_gmm.py` trên branch này cũng mặc định dùng `feature_extractor=auto`; với latent RAE  $16 \times 16 \times 768$ , nó sẽ chọn `pyramid_16k`, tức pool/proj latent về  $4 \times 4 \times 1024$  rồi flatten thành 16384 chiều trước khi fit GMM. Trên máy RAM lớn có thể ép flatten; builder giờ preallocate đúng một ma trận  $N \times D$  float32

và standardize in-place, nên full latent vector không còn cần mmap trên đĩa chỉ để né thêm bản copy RAM. Nếu máy không đủ RAM thì mới ép xuống spatial\_mean làm fallback tiết kiệm bộ nhớ.

Nếu chạy trên Kaggle TPU v5e-8, dùng notebook `raes-jax-celeba-kaggle-tpuv5e8-sitdh-b-moe1.ipynb`. Bản này cố định biến thể CelebA Stage 2 là SiTDH-B + moe1, sync dependency của repo vào /tmp/.venv, tự xóa cờ executable-stack mà Kaggle có thể chặn trên jaxlib, chạy bước xác nhận TPU trong một tiến trình Python mới, giữ Stage 1 và Stage 2 ở TPU, đồng thời build fid\_ref bằng đúng detector backend dùng cho online FID, build thêm celeba256\_source\_gmm.npz, và giữ cadence checkpoint mặc định ở mốc 210000 step. Block source sinh ra dùng condition\_dim=16, hidden\_channels=256, router\_temperature=2.0, balance\_loss\_weight=0.1, entropy\_loss\_weight=1.0e-2, và var\_kl\_loss\_weight các cell train/resume Stage 2 trên toàn bộ bộ notebook moe1 của branch này cũng đã thống nhất về training.num\_workers=16, training.prefetch\_factor=4, eval.prefetch\_factor=4, training.log\_raft\_loss và training.log\_activation\_stats=true; riêng cell build FID stats vẫn giữ src\_jax/build\_fid\_stats.py -num-workers 32.

Nếu đã có thư mục run Orbx của SiTDH-B + moe1 và cần train tiếp, dùng notebook `raes-jax-celeba-kaggle-tpuv5e8-sitdh-b-moe1-resume-only.ipynb`. Notebook này đã được rút xuống thành bản resume-only cho trường hợp bắt đầu từ output archive của notebook cũ: cell đầu chạy lệnh `unzip -o /kaggle/input/notebooks/kieuhongquan/rae-jax/_output_.zip -d /kaggle/working`, sau đó mới kiểm tra repo đã có sẵn, chạy `uv sync, fix jaxlib`, lấy secret wandb, kiểm tra path dataset/FID/GMM, rồi tự tìm thư mục CelebA256\_SiTDH-B\_DINOv2-B\_moe1\_jax\_tpuv5e8-\* mới nhất bên dưới /kaggle/working/results\_jax\_tpu/, rồi mới tìm thư mục checkpoint\_<step>/ mới nhất trong workdir đó trước khi truyền -workdir vào src\_jax/train.py. Runtime tiếp tục restore latest\_step() từ checkpoint mới nhất, nên notebook này không còn hardcoded cả thư mục run có timestamp lẫn checkpoint\_100000. Nếu workdir đích là legacy run được tạo trước khi cơ chế wandb\_run.json tồn tại, cần thêm -wandb-run-id <existing\_run\_id> một lần để notebook resume đúng chính run W&B cũ đó.

Branch này cũng giữ song song bộ notebook TPU CelebA-HQ cho learned-source: `raes-jax-celebahq-kaggle-tpuv5e8-sitdh-b-moe1.ipynb`, và `raes-jax-celebahq-kaggle-tpuv5e8-sitdh-b-moe1-resume-only.ipynb`. Chúng dùng chung learned-source stack moe1 và backend overlay, nhưng tách riêng flow chuẩn hoá dữ liệu, tên artifact, và mặc định run name cho pipeline CelebA-HQ.

## 4. Cấu hình và ánh xạ sang JAX

### 4.1. Các block config chính

Tất cả entrypoint quan trọng đều dựa trên YAML của repo. Các block top-level:

- stage\_1,
- stage\_2,
- transport,
- sampler,
- guidance,
- misc,
- training,
- eval.

## 4.2. Ma trận script và block config

| Block     | src_jax/train.py | src_jax/sample.py | src_jax/sample.py | src_jax/sample.py |
|-----------|------------------|-------------------|-------------------|-------------------|
| stage_1   | yes              | yes               | yes               | yes               |
| stage_2   | yes              | yes               | yes               | no                |
| transport | yes              | yes               | yes               | no                |
| sampler   | yes              | yes               | yes               | no                |
| guidance  | yes              | yes               | yes               | no                |
| misc      | yes              | yes               | yes               | no                |
| training  | yes              | no                | no                | no                |
| eval      | yes              | no                | no                | no                |

## 4.3. Block stage\_1

Adapter JAX không tạo schema mới cho Stage 1. Nó đọc trực tiếp:

- `encoder_config_path` hoặc `encoder_params.dinov2_path`,
- `pretrained_decoder_path`,
- `normalization_stat_path`,
- `encoder_input_size`.

Các giá trị này được chuyển sang encoder RAE của backend NNX để phục vụ reconstruction và decode latent khi sampling Stage 2.

Nếu cần tính stat riêng cho dataset mới, có thể dùng:

```
python3 src_jax/build_stage1_stats.py \
  --config <stage1_config> \
  --input <train_imagefolder> \
  --output <stage1_stat.pt> \
  --set stage_1.params.normalization_stat_path=<bootstrap_identity_stat.pt>
```

Trong đó file bootstrap identity stat chỉ cần chứa `mean = 0` và `var = 1`. Mục tiêu là để pass tính stat đầu tiên không bị chuẩn hóa theo dataset khác, nhưng vẫn thỏa contract load stat của backend NNX.

## 4.4. Block stage\_2

Một số key quan trọng:

- `target`: chỉ dùng để suy ra backbone NNX tương ứng;
- `ckpt`: có thể là file PyTorch `.pt` hoặc thư mục Orbx, nhưng trên branch này nó phải tương thích với shape của SiTDH;
- `input_size`, `patch_size`, `in_channels`;
- `hidden_size`, `depth`, `num_heads`: với SiTDH đây là các cặp encoder/decoder của backbone DH;

- `class_dropout_prob`: tỉ lệ label dropout cho CFG; với notebook CelebA-HQ một lớp trên đường JAX thì giá trị này được đặt về 0.0;
- các toggle như `use_rope`, `use_rmsnorm`, `use_swiglu`, `wo_shift`, `use_pos_embed`.

Với config mặc định của branch này, target sẽ là SiTDH và adapter JAX sẽ ánh xạ nó sang backend `lightning_ddt` trong khi vẫn giữ `interface_class=sit`. Các target DDT legacy cũng đi cùng đường `lightning_ddt`.

#### 4.5. Block guidance

Hai mode chính:

- `cfg`: adapter dùng chính model làm conditional và unconditional pass, với nhãn null mặc định bằng `num_classes`;
- `autoguidance`: adapter load thêm `guidance.guidance_model` làm guide network.

#### 4.6. Block training

Một số key được ánh xạ trực tiếp:

```
training:
  global_seed: 0
  epochs: 1400
  global_batch_size: 1024
  ema_decay: 0.9995
  num_workers: 4
  prefetch_factor: 2
  random_flip: true
  log_every: 100
  ckpt_every: 5000
  sample_every: 10000
  base_lr: 0.0002
  final_lr: 0.00002
  beta: [0.9, 0.95]
  wd: 0.0
  schedule_type: linear
  log_rae_latent_stats: false
  log_activation_stats: false
```

Lưu ý:

- nếu config chỉ cho `epochs`, adapter sẽ suy ra `total_steps` từ `num_train_samples`;
- optimizer mặc định vẫn là AdamW;
- scheduler được chuẩn hóa về các mode đơn giản như `constant`, `linear`, `cosine`;
- nếu `num_workers > 0`, có thể tăng `prefetch_factor` để queue trước nhiều batch hơn ở host-side PyTorch loader của đường JAX mà không đụng tới backend checkout;
- `random_flip` điều khiển việc chèn `RandomHorizontalFlip()` trước Stage 1 encode trên raw-image path; các config CelebA-HQ của branch này mặc định bật nó cho train nếu không override lại;

- nếu bật `log_rae_latent_stats=true`, đường JAX sẽ log `train_rae_latent_rms` và `train_rae_latent_var` cho latent RAE thực sự đi vào Stage 2;
- nếu bật `log_activation_stats=true`, đường JAX sẽ yêu cầu backend trả intermediate feature rồi log RMS/variance cho output của SiTDH và từng block encoder/decoder, ví dụ `train_sitdh_output_rms`, `train_sitdh_act_enc_00_rms`, và `train_sitdh_act_dec_01_var`.

#### 4.7. Block source

Trên branch `jax-sit-dh-moe1`, block source bật đường learned-source GMM + CNN-MoE. Khi `source.enabled=true`, adapter sẽ đổi `interface_class` từ `sit` sang `sit_gmm_moe1`.

```
source:
  enabled: true
  kind: gmm_moe1
  gmm_stats_path: artifacts/celeba256_source_gmm.npz
  num_modes: 4
  condition_dim: 16
  hidden_channels: 256
  router_temperature: 2.0
  soft_moe: true
  balance_loss_weight: 0.1
  entropy_loss_weight: 1.0e-2
  var_kl_loss_weight: 1.0
  target_variance: 1.0
  logvar_min: -8.0
  logvar_max: 4.0
  var_floor: 1.0e-5
  posterior_eps: 1.0e-6
  weight_prior: 1.0e-2
  em_iters: 100
  em_tol: 1.0e-4
  em_restarts: 3
  dead_count_threshold: 1.0
  active_mode_fraction_threshold: 0.01
```

- `gmm_stats_path` trỏ tới artifact `.npz` được build bởi `src_jax/build_source_gmm.py`; script này cũng lưu luôn cách trích feature cho GMM. Trên branch DH, mode auto mặc định sẽ rơi về `pyramid_16k`: latent RAE  $16 \times 16 \times 768$  được pool/proj về  $4 \times 4 \times 1024$  rồi mới flatten thành 16384 chiều. Trên máy RAM lớn có thể ép flatten; builder giờ preallocate đúng một ma trận  $N \times D$  kiểu float32 và standardize in-place, nên full latent vector không còn cần memmap trên đĩa chỉ để né thêm bản copy RAM. Chỉ dùng `spatial_mean` khi cần fallback tiết kiệm RAM;
- `num_modes` là số component GMM đồng thời là số expert của MoE;
- `condition_dim` là chiều embedding mode trước khi broadcast bias vào trunk CNN;
- `hidden_channels` là độ rộng trunk/source experts; với latent RAE CelebA-HQ có shape  $B \times 16 \times 16 \times 768$ , notebook mặc định tăng lên 256 thay vì giữ mức hẹp của flow VAE;
- `router_temperature` và `soft_moe` điều khiển độ sắc của router và việc dùng gating mềm hay straight-through;



- `balance_loss_weight`, `entropy_loss_weight`, và `var_kl_loss_weight` là các regularizer phụ cộng vào objective flow-matching chính;
- `weight_prior`, `em_iters`, `em_tol`, `em_restarts`, `dead_count_threshold`, và `active_mode_fraction_thresh` phải khớp recipe đã dùng để build artifact GMM.

#### 4.8. Block eval

Đường JAX giờ dùng `block eval` cho cả validation loss lẫn online FID. Các key `data_path`, `eval_every`, `batch_size`, `num_workers`, `prefetch_factor`, `random_flip`, `max_batches`, và `eval_model` sẽ điều khiển held-out validation loop trong `src_jax/train.py`. Với `fid_ref`, nên ưu tiên file `.pkl/.pickle` được build bởi `src_jax/build_fid_stats.py`; nếu đưa file `.npz` cũ vào, adapter vẫn tự chuyển nó sang định dạng pickle mà backend NNX hiểu được. Trên đường JAX, metric FID-4K (`cfg=...`) mặc định chấm EMA; nếu bật `fid_eval_model`, adapter sẽ log thêm FID-4K/model (`cfg=...`) cho online model mà không thay metric EMA mặc định.

#### 4.9. Override từ CLI

Các entrypoint JAX cho phép override nhanh bằng:

```
python3 src_jax/train.py \
  --config <config> \
  --set training.global_batch_size=256 \
  --set training.prefetch_factor=8 \
  --set eval.prefetch_factor=4 \
  --set training.log_rae_latent_stats=true \
  --set training.log_activation_stats=true \
  --set guidance.scale=1.5
```

Mục tiêu là giữ đúng một schema YAML, nhưng vẫn cho phép chỉnh nhanh như CLI.

### 5. Vận hành, artifact và FID

#### 5.1. Sampling Stage 2 trên đường JAX

##### 5.1.1. Sampling nhanh

```
python3 src_jax/sample.py \
  --config <sample_config> \
  --seed 42 \
  --class-labels 207,360 \
  --output sample_jax.png
```

##### 5.1.2. Sampling phân tán

```
python3 src_jax/sample_ddp.py \
  --config <sample_config> \
  --sample-dir samples_jax \
  --num-samples 50000 \
  --per-proc-batch-size 4 \
  --label-sampling equal \
  --fid-ref /path/to/reference_stats.npz
```

Artifact đầu ra:

- các file PNG theo index;
- các shard .npz theo rank nếu bật `-save-npz`;
- giá trị FID in ra terminal nếu cung cấp `-fid-ref`.

## 5.2. Build reference statistics cho FID

```
python src/build_fid_stats.py \  
  --input /path/to/reference_images \  
  --output /path/to/reference_stats.npz \  
  --device cpu \  
  --batch-size 64 \  
  --num-workers 32 \  
  --num-threads 96
```

Đây là đường torch-fidelity chung cho nhánh XLA/PyTorch. Nếu cần `fid_ref` cho online FID ở JAX, nên build bằng detector backend-native:

```
python3 src_jax/build_fid_stats.py \  
  --input /path/to/reference_images \  
  --output /path/to/reference_stats.pkl \  
  --batch-size 64 \  
  --num-workers 8
```

Trên host JAX như Kaggle TPU, nên giữ `-num-workers` ở mức vừa phải (0-8 thường là đủ). Script này dùng worker kiểu spawn khi `num_workers > 0`, nên tránh được cảnh báo `os.fork()` thường gặp với JAX đa luồng.

## 5.3. Artifact của Stage 2 training

### 5.3.1. Đường XLA

Một experiment trong `results/` thường có:

- `log.txt`,
- `checkpoints/<step>.pt`,
- `fid_eval/step_<step>/...` nếu bật online FID.

### 5.3.2. Đường JAX

Một run trong `results_jax/` thường có:

- `jax_adapter_config.json`,
- thư mục checkpoint Orbx do backend quản lý,
- media và scalar trên wandb nếu bật `-wandb`,
- toàn bộ workdir có thể được đẩy lên Hugging Face nếu truyền `-hf-repo-id`.

## 5.4. Đẩy model lên Hugging Face

```
python3 src_jax/push_hf.py \
  --path results_jax/<run_name> \
  --repo-id <hf_user_or_org>/<repo_name>
```

Hoặc gán thẳng vào lệnh train:

```
python3 src_jax/train.py \
  --config <config> \
  --data-path <train_root> \
  --hf-repo-id <hf_user_or_org>/<repo_name>
```

## 5.5. Các lưu ý vận hành quan trọng

- Đường JAX cố ý giữ nguyên schema YAML của repo để giảm chi phí bảo trì.
- `stage_2.ckpt` trên đường JAX có thể là PyTorch hoặc Orbx, nhưng cách load sẽ khác nhau.
- Đường JAX giờ cũng có validation loss định kỳ qua block `eval`, ngoài online FID.
- FID trên đường JAX nên dùng reference stats build bởi `src_jax/build_fid_stats.py` để cùng detector với backend; nếu cần, adapter vẫn chuyển `.npz` cũ sang pickle nội bộ.
- Online FID ở JAX mặc định chấm EMA. Nếu cần đối chiếu với model hiện thời, bật `eval.fid_eval_model=true` để log thêm metric FID-4K/model (`cfg=...`) bên cạnh series EMA mặc định.
- Nếu chỉ cần inference Stage 1 ở JAX, dùng `src_jax/stage1_sample.py`.
- Nếu cần stat Stage 1 hoặc reconstruction cả thư mục ở JAX, dùng `src_jax/build_stage1_stats.py` và `src_jax/reconstruct_folder.py`. Các lệnh này có thể dùng YAML chỉ có `stage_1`, không cần `stage_2.target`.
- Nếu chạy trên Kaggle với CelebA cho branch learned-source này, bắt đầu từ notebook TPU `raes-jax-celeba-kaggle` để giữ đúng flow clone repo, đặt `UV_PROJECT_ENVIRONMENT=/tmp/.venv` và `UV_CACHE_DIR=/tmp/uv-cache`, chạy `uv sync -q`, tải dataset Kaggle CelebA, center-crop và resize sang `ImageFolder`, rồi chạy các bước phụ thuộc package qua `uv run`. Flow notebook này giờ build thêm artifact `celeba256_source_gmm.npz` qua `src_jax/build_source_gmm.py`. Trên latent RAE DH lớn, script này mặc định rơi về `feature_extractor=py` tức pool/proj latent về 16384 chiều trước khi fit GMM. Trên máy RAM lớn có thể ép `flatten`; builder giờ preallocate đúng một ma trận  $N \times D$  float32 và standardize in-place. Chỉ khi thật sự thiếu RAM mới nên ép xuống `spatial_mean`, rồi mới ghi config Stage 2 với block `source.enabled=true`. Route TFDS hay Hugging Face cho CelebA-HQ vẫn còn trong repo, nhưng không còn là flow mặc định của branch này.
- Nếu phần cứng là Kaggle TPU `v5e-8`, dùng notebook `raes-jax-celeba-kaggle-tpuv5e8-sitdh-b-moe1.ipynb` bản này cố định biến thể Stage 2 là `SiTDH-B + moe1`, chuyển FID và build reference stats sang detector backend-native của JAX, đồng thời cũng sync dependency của repo vào `/tmp/.venv` trước các bước `uv run`, tự xóa cờ `executable-stack` mà Kaggle có thể chặn trên `jaxlib`, rồi kiểm tra `jax/TPU` bằng tiến trình Python mới. Notebook này cũng chuẩn hoá CelebA sang `ImageFolder` trước khi build Stage 1 stat, build `fid_ref`, build `celeba256_source_gmm.npz`, export `RAE_JAX_REBUILD_BACKEND=1`, và giữ mốc checkpoint mặc định ở 210000 step.

- Nếu cần cùng flow Kaggle TPU đó nhưng muốn train biến thể SiTDH-B + moe1, dùng notebook `raes-jax-celeba-kaggle-tpuv5e8-sitdh-b-moe1.ipynb`. Bản này giữ toàn bộ fix Kaggle/JAX hiện có, đổi Stage 2 sang recipe DH/two-tower SiTDH-B với `hidden_size=[768, 2048]`, `depth=[12, 2]`, `num_heads=[12, 16]`, `use_pos_embed=true`, `class_dropout_prob=0.0`, ghi config CelebA256\_SiTDH-B, build artifact GMM trước train, và dùng cùng cadence checkpoint 210000 step.
- Nếu đã có sẵn một run Orbox của SiTDH-B + moe1 và cần train tiếp từ checkpoint hiện có, dùng notebook `raes-jax-celeba-kaggle-tpuv5e8-sitdh-b-moe1-resume.ipynb`. Notebook này là bản resume-only tối giản cho trường hợp bắt đầu từ output archive của notebook cũ: cell đầu chạy lệnh `unzip -o /kaggle/input/notebooks/kieuhongquan/rae-jax/_output_.zip -d /kaggle/working`, sau đó chỉ kiểm tra repo đã có sẵn, chạy `uv sync`, lấy secret wandb, kiểm tra path dataset/FID/GMM, export `RAE_JAX_REBUILD_BACKEND=1`, rồi tự tìm thư mục run CelebA256\_SiTDH-B\_DINOv2-B\_moe1\_jax\_tpuv5e8 mới nhất bên dưới `/kaggle/working/results_jax_tpu/` và thư mục `checkpoint_<step>/` mới nhất trong `workdir` đó trước khi truyền `-workdir` vào `src_jax/train.py`. Runtime cũng tiếp tục restore bằng `latest_step()`, nên notebook này không còn `hardcode checkpoint_100000`.
- Nếu cần huấn luyện Stage 1 kiểu GAN đầy đủ, hiện vẫn phải xem đây là phần chưa được JAX hóa trong branch này.

## 5.6. Checklist thực tế trước khi chạy dài

1. Xác nhận `stage_1` và `stage_2` khớp latent shape.
2. Xác nhận dữ liệu train và val đúng dạng `ImageFolder`.
3. Với dataset mới, build lại `stage1_stat.pt` thay vì tái dùng stat của ImageNet nếu muốn latent normalization khớp dữ liệu hơn.
4. Build `fid_ref` trước nếu muốn FID ổn định.
5. Export đủ biến wandb trước khi bật `-wandb`.
6. Nếu muốn upload lên Hugging Face, xác nhận token nằm trong biến môi trường được chỉ định bởi `-hf-token-env`.
7. Với JAX sampling số lượng lớn, chọn `-per-proc-batch-size` đủ an toàn theo bộ nhớ thiết bị.